建筑场景下的多模态大模型

从感知理解到智能体决策

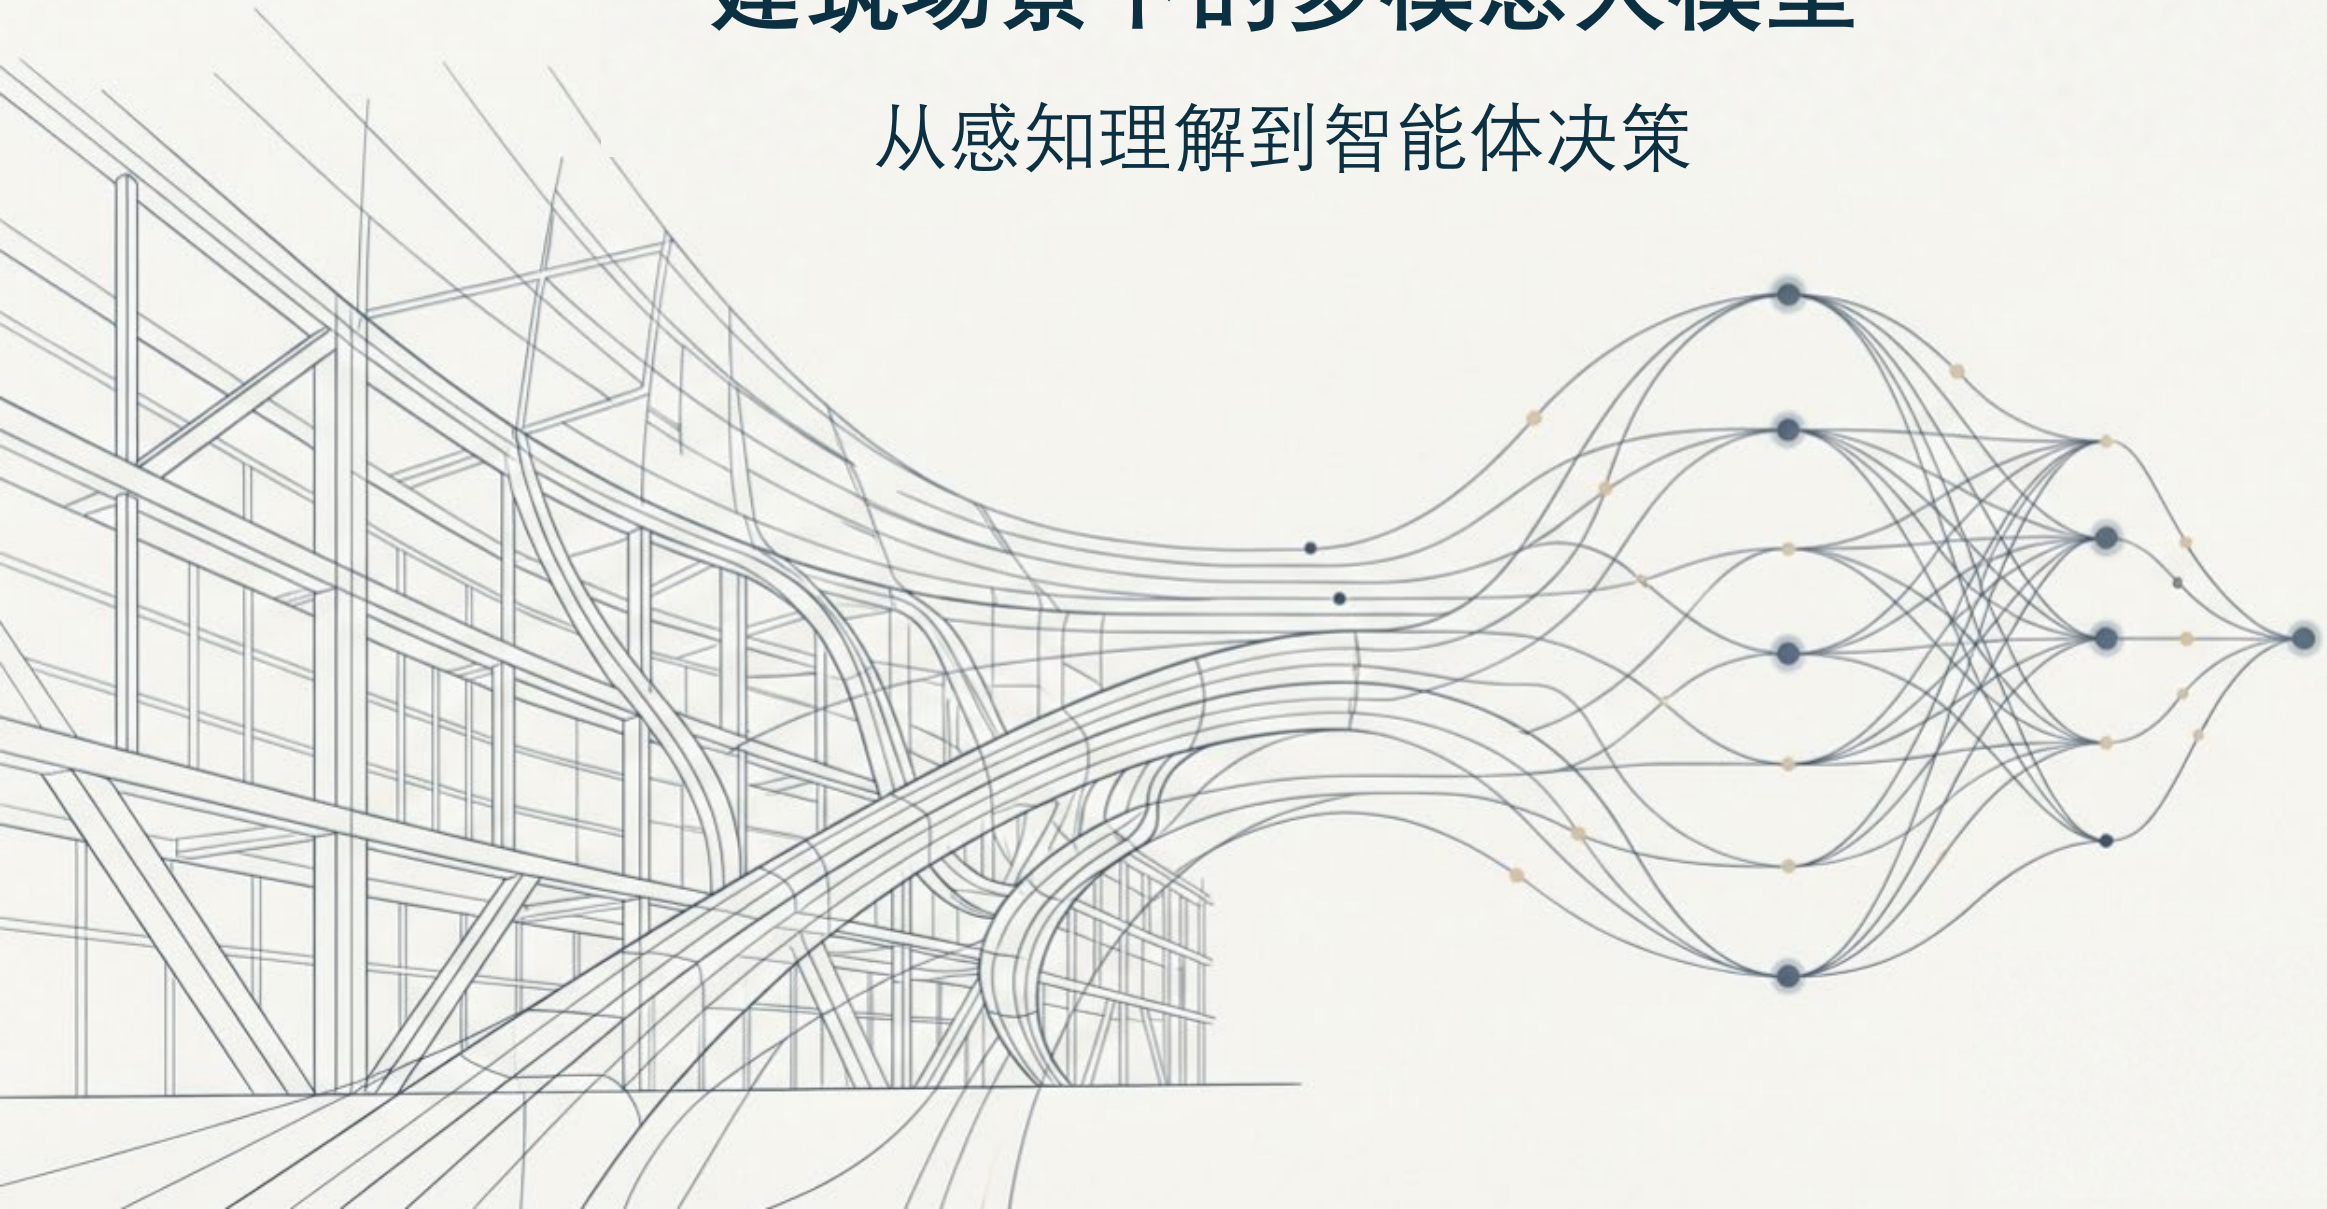

为什么是现在?两大技术趋势的交汇

模型的进化:多模态能力的爆发

模型能力从处理单一文本的语言大模型(LLMs),进化到能够同时理解和推理图像、文本与结构化数据的多模态大模型(MLLMs),如GPT-4V和Gemini,实现了质的飞跃。

行业的变革:建筑全流程数字化

建筑信息模型(BIM)、3D激光扫描点云、物联网(IoT)传感器等技术普及,使得建筑的全生命周期产生了海量、多源、结构化的数字资产,为AI应用提供了前所未有的数据土壤。

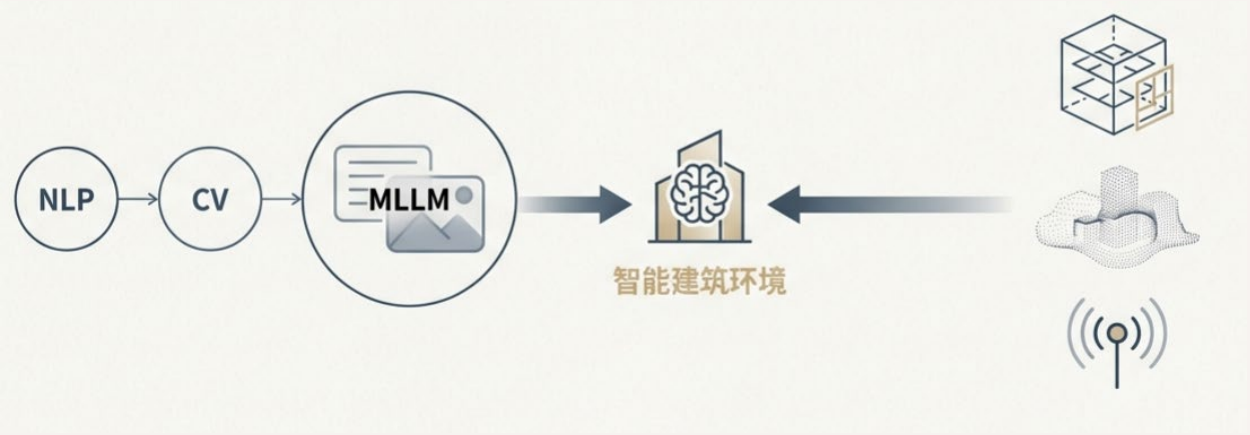

智能建筑的全景图:从“看懂”到“决策”

感知与理解

对建筑数据进行基础解析与阐释的能力

规划与决策

基于环境理解进行推理并生成行动建议的能力

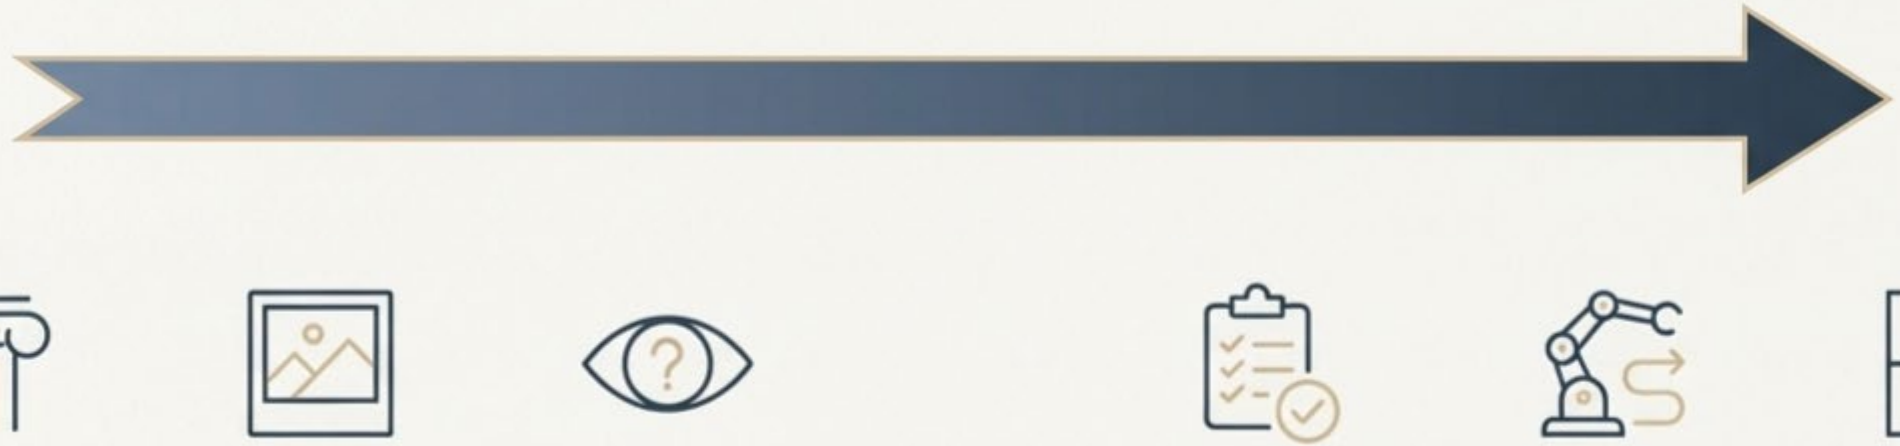

物体识别
(识别与柱)

场景描述
(描述施工现场)

视觉问答
(立面上有几扇窗)

合规性检查
(坡道符合规范)

任务规划
(系统巡检序列)

空间优化
(优化布局)

建筑工地:一个高风险、高价值的AI视觉“盲区”

为何重要

- **安全监管:**施工现场是事故高发区,AI可用于实时风险预警。
- **进度管理:**自动分析作业流程,提升项目管理效率。
- **质量控制:**监控施工过程,确保符合规范。

为何困难

- 环境复杂性:
  - 光照变化大
  - 目标遮挡频繁
  - 作业活动多样
  - 噪声干扰严重

- 数据缺失 :
  - “缺乏专门针对建筑场景的视频数据集与标准 化评测体系,导致模型无法有效迁移与优 化。”

- **视角的重要性**
  - 第一人称视角(由工人佩戴设备采集)能更真实地反映作业状态、视觉焦点和操作细 节,相比出固定监控具有更高的研究价值。

当前研究现状:聚焦于“感知理解”的基石

现有研究主要集中于利用多模态大模型的强大表征能力,对复杂的建筑数据(如图像、文本、BIM模型、点云)进行解析和对齐,为下游任务奠定基础。

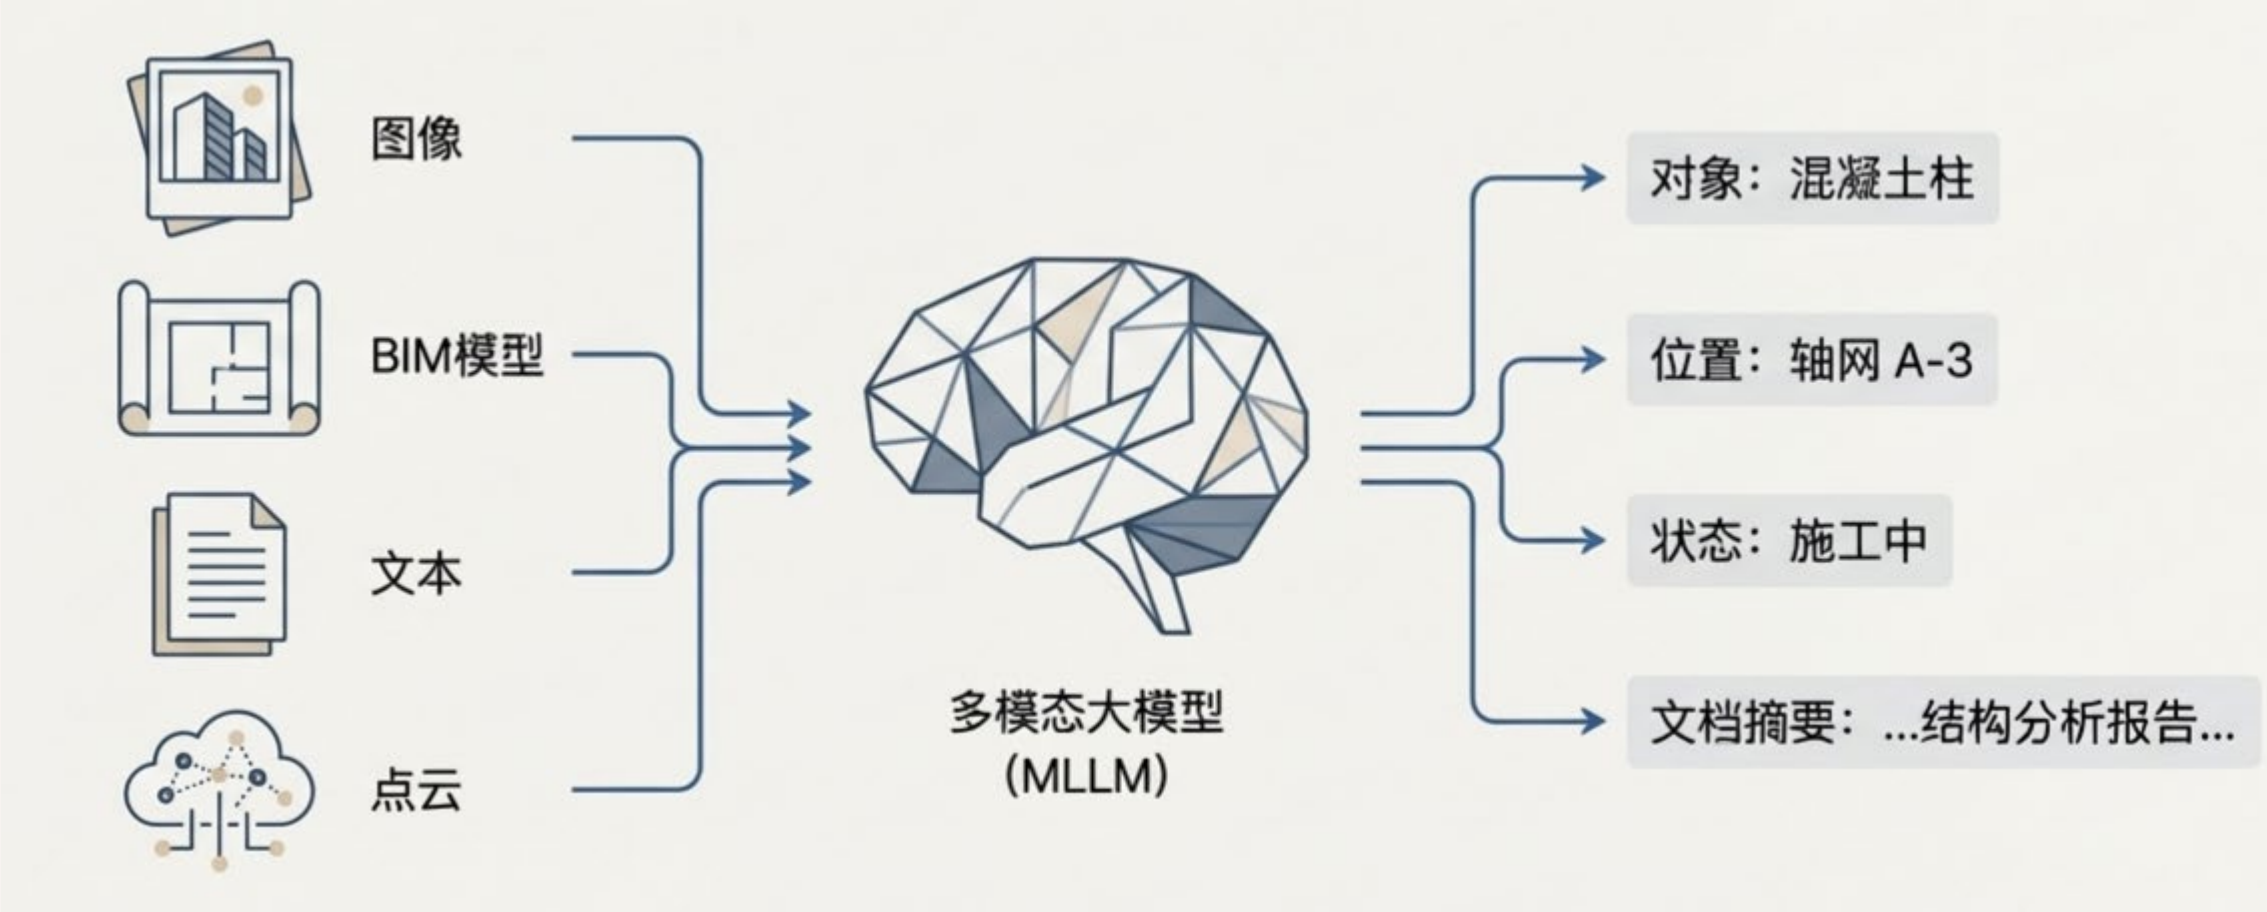

文献解读 1:面向BIM的视觉问答框架

参考论文:StructVQA: A Framework for VQA on Building Information Models, Fictional Conference, 2023

核心贡献

提出一个能理解BIM模型几何与语义信息,并回答关于建筑结构自然语言问题的框架。

主要局限

仅限于信息检索和“问答”,无法基于理解进行空间推理或生成可执行的修改建议。

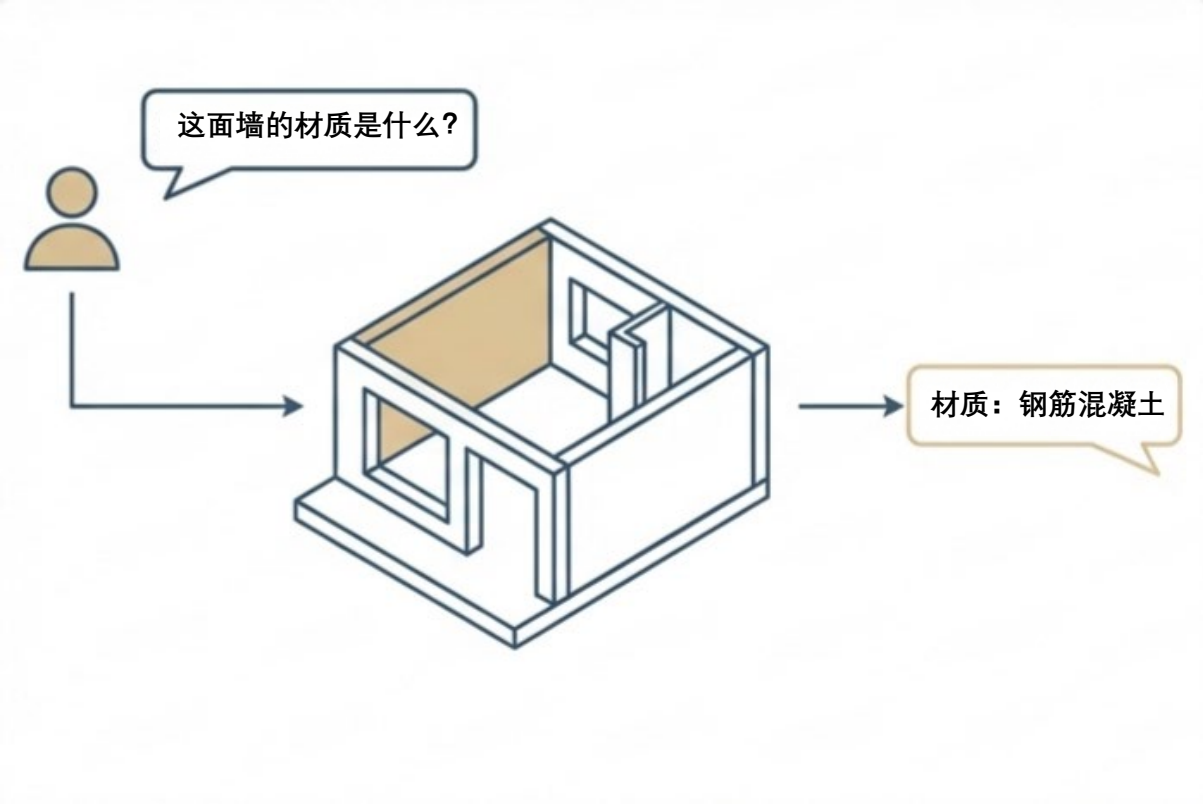

文献解读2:基于点云的施工现场进度描述

参考论文:Scan2Text: End-to-End Scene Description for Construction Monitoring, Fictional Journal, 2024

核心贡献

实现了从3D点云扫描数据直接生成描述施工进度的自然语言文本。

主要局限

模型是描述性的,而非指令性的。它能报告“什么已经完成”,但无法预测风险或建议“下一步该做什么”。

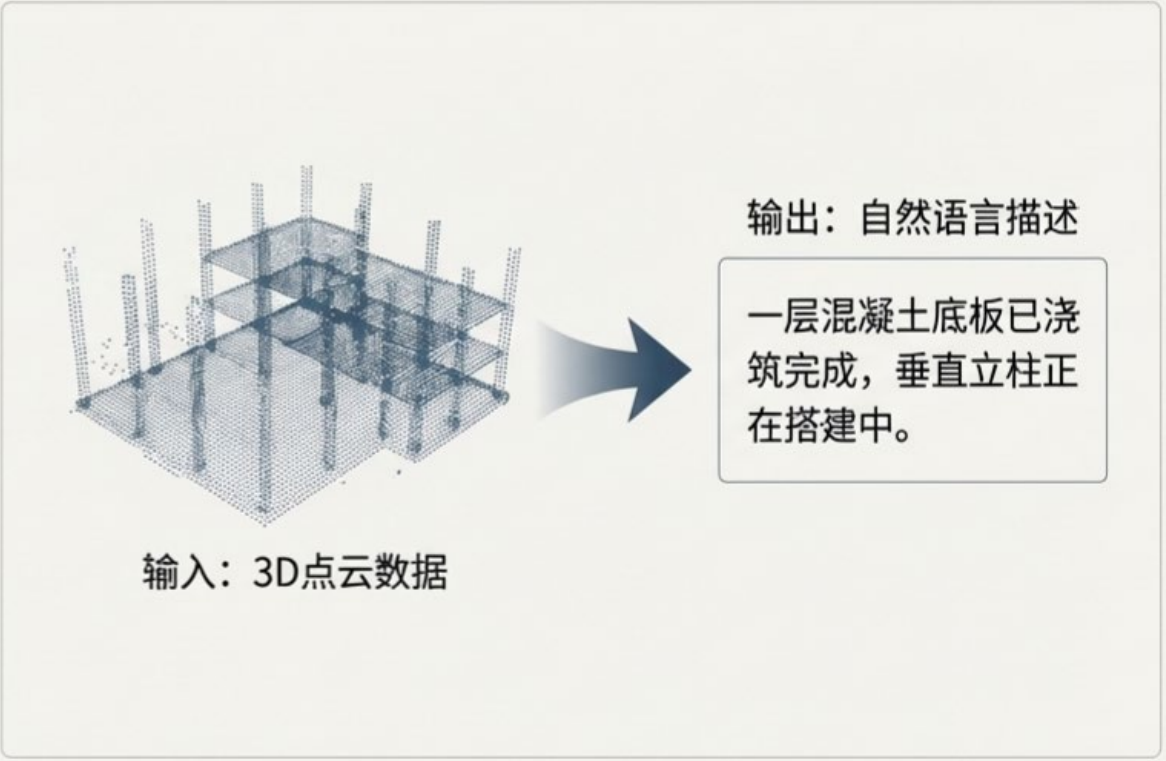

文献解读3:趣味视频的理解

参考论文:FunQA: Towards Surprising Video Comprehension

核心贡献

实现了从3D点云扫描数据直接生成描述施工进度的自然语言文本。

主要局限

模型是描述性的,而非指令性的。它能报告“什么已经完成”,但无法预测风险或建议“下一步该做什么”。

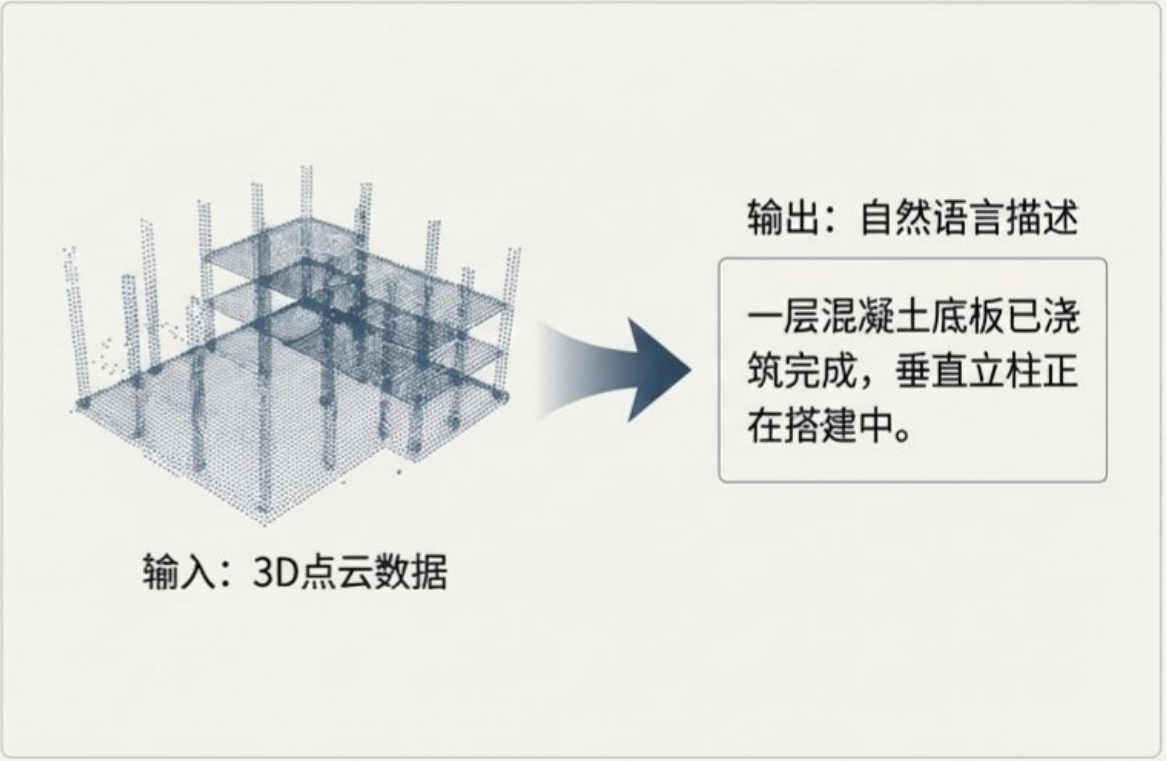

从通用智能到行业应用:一道难以逾越的鸿沟

通用AI研究前沿

垂直领域应用

幽默理解、创意评估、时序逻辑、因果推理

光照多变、目标遮挡、专业知识、高风险决策

尽管通用视频模型在理解日常场景方面取得了显著进展,但当它们被部署到建筑施工这类高风险、专业性强的垂直领域时,其性能会因缺乏领域知识和无法适应复杂环境而严重受限。

关键的飞跃：从“理解”到“行动”的鸿沟

已解决的问题 (The What)

- 这是什么?
- 它在哪里?
- 有多少个?

现有模型善于识别和量化。

待解决的挑战 (The So What)

- 下一步该做什么?
- 这是否合规?
- 如何优化这个设计?

真正的价值在于赋能规划与决策。

我们的方案:面向建筑场景的智能体决策框架

为跨越这一鸿沟,我们提出了一个智能体框架。该框架不仅能多模态地感知和理解建筑环境,更重要的是,它能在复杂的约束条件下进行推理、规划,并最终生成可执行的决策或行动序列。

破局之道：为建筑行业打造专有视频理解解“蓝图”

构建基石

全新数据集

构建首个面向第一人称施工场景的视频基准CSVBench,包含精细的语义标注和多层次问答任务。

研发工具

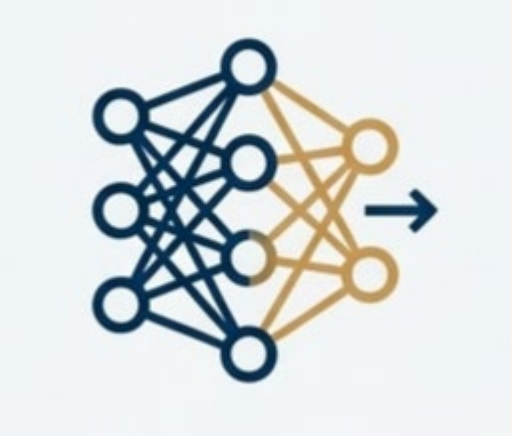

定制化模型

提出一种参数高效的微调框架,使预训练模型能低成本、高效率地适应施工领域的独特挑战。

确立标准

评测体系

构建首个面向第一人称施工场景的视频基准CSVBench,包含精细的语义标注和多层次问答任务。

CSV-Bench:首个面向第一人称施工场景的多层次视频数据集

数据概览

数据来源

与华凤科技有限公司合作,采集自真实施工现场管理系统。 视角:工人佩戴的头戴式设备拍摄的第一人称视角视频。 覆盖范围:覆盖钢筋、模板、砌筑等10余个核心工种。

数据规模（Scale）

8,000+

个高质量视频片段（15-30秒）

40,000+

个多层次问答对

构建方法

方法创新

采用“人工标注+规范知识检索+大语言模型生成”的混合构建范式。

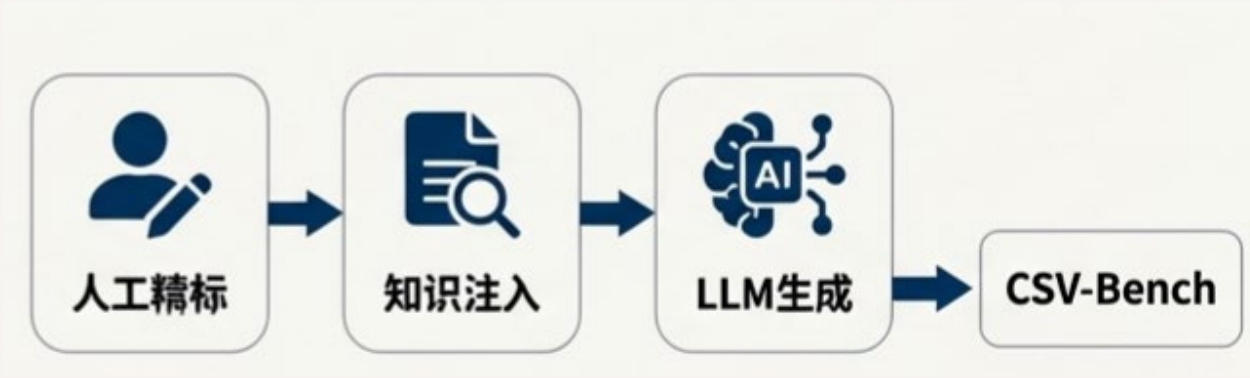

精细化标注体系:从动作捕捉到意图推理

为实现对施工行为的深层理解,我们设计了包含八大维度的结构化语义标签体系,为每个视频片段提供丰富的上下文信息。

动词
核心操作（搬运，焊接等）

名词
设计的工具材料（钢筋，焊枪等）

动作执行者
执行动作的人（钢筋工，电焊工）

空间位置
动作发生的区域（脚手架，电梯井）

动作结果
动作完成后的状态（钢筋捆扎完成）

预测下一步动作
基于工序的合理预测（准备浇筑混凝土）

工序类型
归属的施工大类（钢筋工程）

开放性描述核心
自然语言描述上下文

四级问答设计:系统化评测从“看见”到“预见”的全过程

CSV-Bench的问答任务被设计为四个递进的难度等级,旨在全面考察模型从基础感知到高级推理的综合能力。

L4：评估性（Evaluative）
能力要求：结合领域规范进行合规性判断和风险评估。
示例问题：“该工人在高空作业时的安全防护措施是否符合规范？”

L3：预测性（Predictive）
能力要求：基于时序线索预测后续可能发生的事件。
示例问题：“完成钢筋绑扎后，工人下一步最可能做什么？”

L2:检测性(Detective)
能力要求:感知细粒度的视觉信息,如数量和位置。
示例问题: “画面中有几名工人在操作?”

L1:描述性(Descriptive)
能力要求:识别视频中显性的视觉元素。
示例问题:“视频中的工人正在使用什么工具?”

专为施工场景设计:参数高效的VideoMAE微调框架

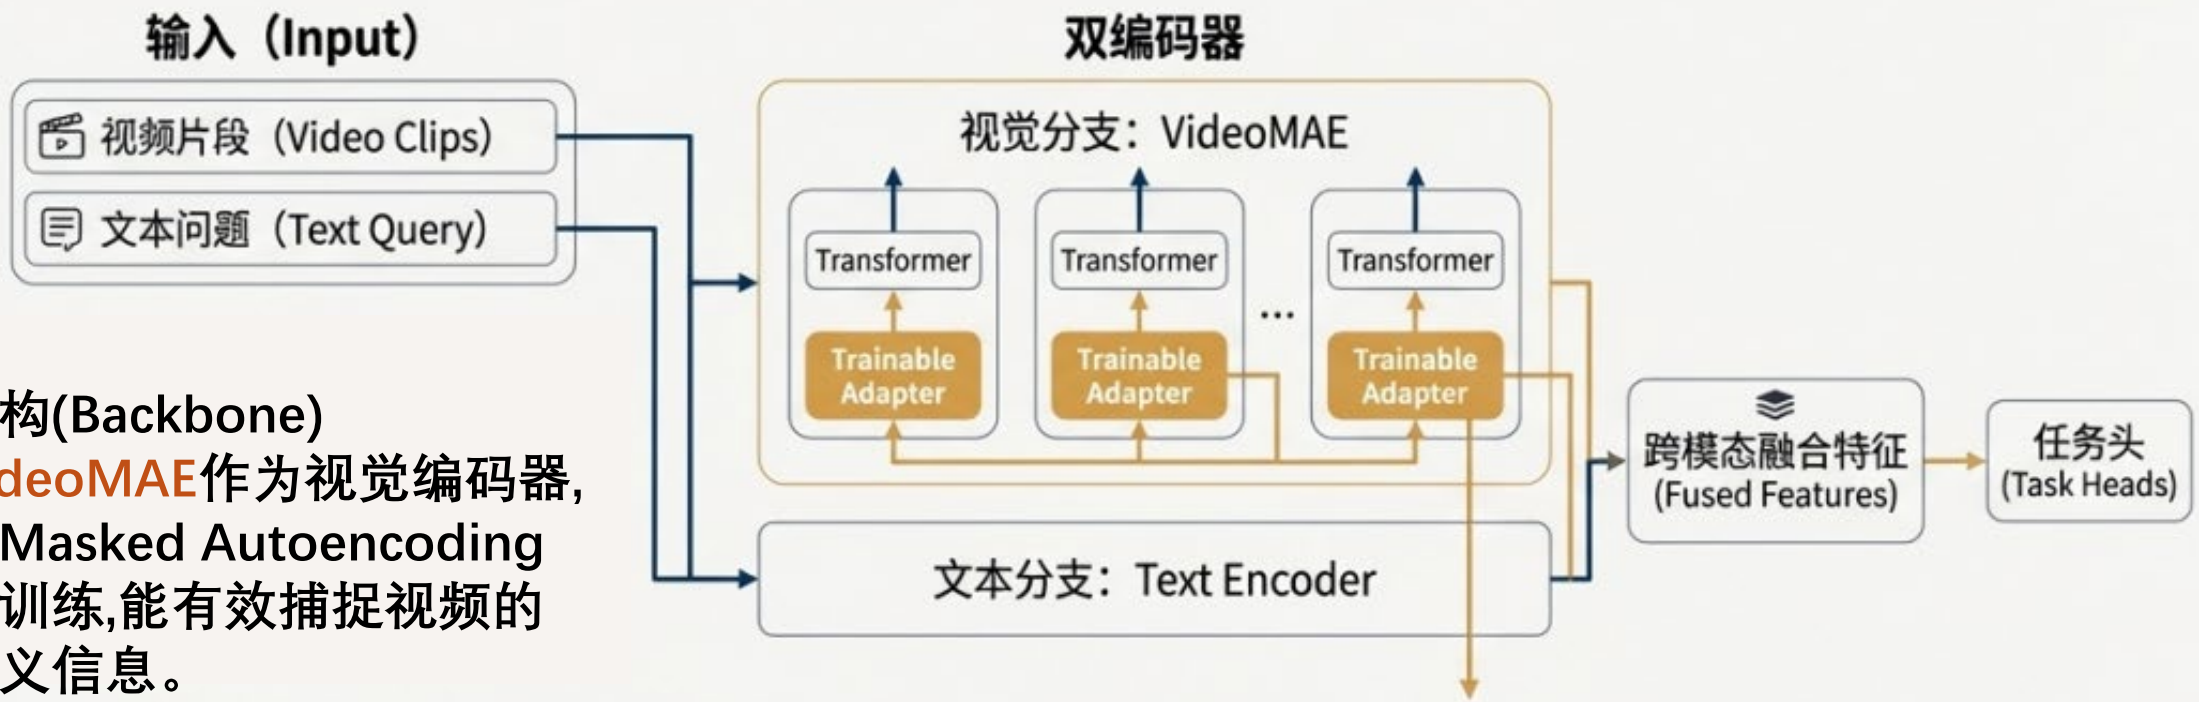

基础架构(Backbone)
采用VideoMAE作为视觉编码器,它通过Masked Autoencoding机制预训练,能有效捕捉视频的时空语义信息。

领域适应策略
参数高效微调：在微调时冻结VideoMAE主干网络的全部参数。
可训练适配器：在Transformer层中插入轻量化的Adapter模块。

为何选择Adapter?
高效:仅需更新极少量参数(占主干网络的3-5%),大幅降低训练成本和GPU显存占用。
有效:在保留预训练模型强大泛化能力的同时,高效学习施工场景的特定领域特征,有效避免过拟合。

一体化多任务学习:实现动作、行为、问答与安全评估的协同

动作识别头

任务:施工动作分类与时序片段定位。

输出:动作类别(如“焊接”)+起止时间戳。

行为理解头

任务:生成场景描述文本,进行因果推理。

输出:自然语言描述(如 “工人在为后续浇筑做准备”)。

视频问答头

任务:支持L1到L4四级难难度的视频问答。

输出:针对问题的具体答案。

安全评估头

任务:检测违规行为,识别潜在风险。

输出:安全评估结果(如 “高风险:未佩戴安全帽”)。

联合优化(Joint Optimization)

$$L_{total} = \lambda_1 L_{action} + \lambda_2 L_{behavior} + \lambda_3 L_{qa} + \lambda_4 L_{safety}$$

说明:通过单一损失函数联合优化所有任务,促使模型学习到更通用、更鲁棒的特征表示。

标准化评测基准:量化模型在真实工业场景中的综合能力

CSV-Bench不仅是一个数据集,更是一个包含标准化任务、多层次指标和多样化基线模型的完整评测框架。

第一部分:评测任务

- 行为识别
- 行为理解
- 视频问答
- 安全评估

第二部分:三层评价指标体系

感知层(Perception Layer)
指标:Top-1/Top-5 Accuracy, mAP
评估内容:底层视觉特征提取和动作识别的准确性。

语义层(Semantic Layer)
指标:BLEU, ROUGE-L
评估内容:生成文本(如场景描述)的流畅性和相关性。

推理层(Reasoning Layer)指标：精确匹配率（ExactMatch），F1分数，并引I入GPT-4o作为辅助评估器。评估内容：对预测性和评估性问题的回答进行准确性、完整性和安全性的综合评分。

第三部分:对比模型

将与CLIP,BLIP-2, LLaVAVideo, Video-LLaMA等代表性模型进行全面对比,验证基准的有效性与挑战性。

未来工作与长远愿景

近期工作

- 扩展到动态环境:将框架应用于实时变化的施工现场,处理视频流和传感器数据。
- 集成人机交互:允许人类专家修正和指导智能体的决策过程。

长远愿景
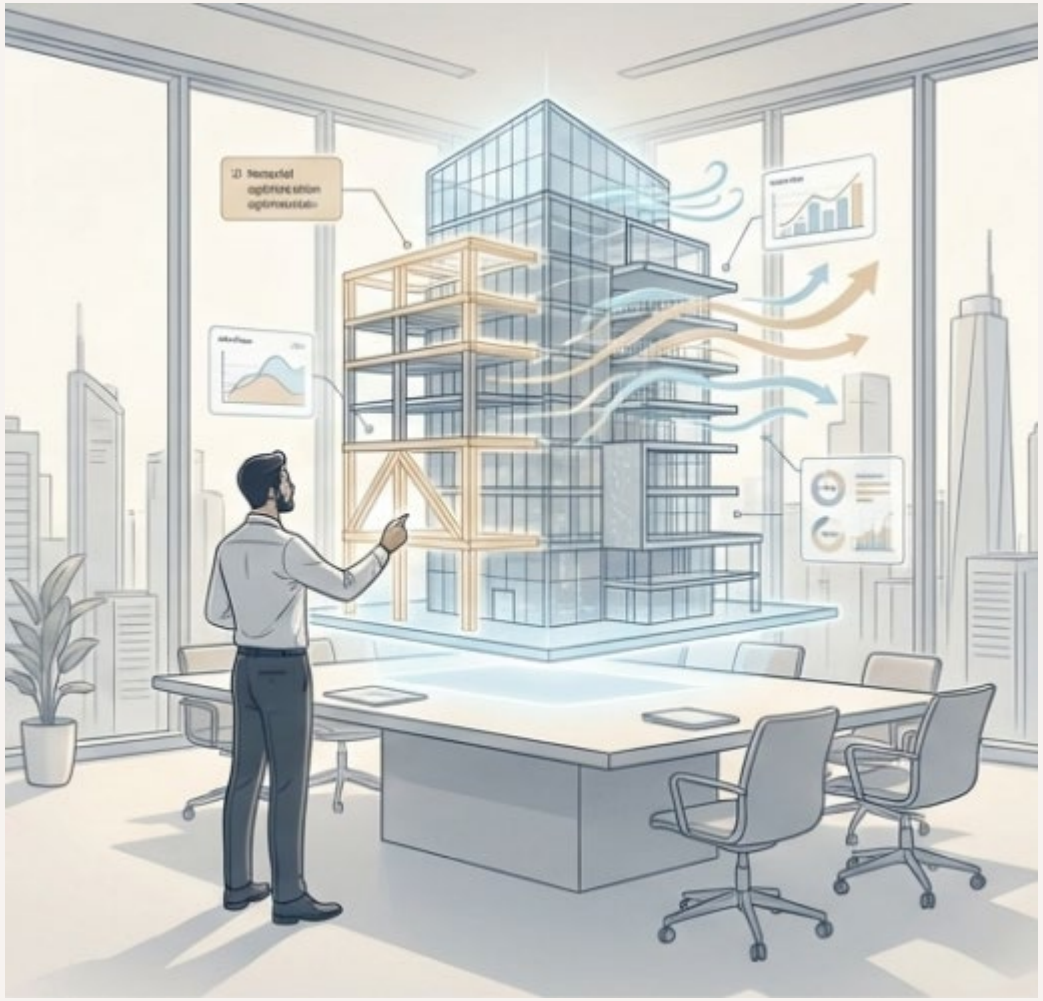
- 最终目标是创造一个能与建筑师、工程师和管理人员无缝协作的“建筑AI副驾”(Co-pilot),提升设计质量、施工效率和运维水平。